

IPFS - Content Addressed, Versioned, P2P File System (DRAFT 3)

Juan Benet
juan@benet.ai

ABSTRACT

IPFS(インタープラネタリーファイルシステム)は、全てのコンピュータデバイスを同じファイルシステムに接続するためのピアツーピア分散ファイルシステムです。ある意味、IPFSはWebに似ていますが一つのGitレポジトリ内でオブジェクト交換を行うBitTorrentのスウォームとみなすことができる。言い換えれば、IPFSは、コンテンツのアドレスのハイパーリンクを持つ高スループットコンテンツアドレスブロックストレージモデルを提供します。これは、一般化されたMerkle DAGを作り出します。用途としては、バージョン管理ファイルシステム、ブロックチェーン、さらには永続するWebを構築するための有用です。IPFSは、分散ハッシュテーブル、インセンティブ設計があるブロック交換、自己認証名前空間の知識を組み合わせて構成されています。またIPFSには単一障害点はなく、ノードは互いに信頼する必要はありません。

1. INTRODUCTION

グローバルな分散ファイルシステムの構築には多くの試みが行われてきました。いくつかのシステムは大きな成功を収め、他のシステムは失敗に終わってしまいました。学問的な試みの中では、AFS~[6]は成功した事例で、今でもなお使用されています。その他~[?]などのシステムは同じようにはうまくいきませんでした。学術系以外の取り組みとして最も成功したシステムは、主に大容量メディア(オーディオおよびビデオ)向けのピアツーピアファイル共有アプリケーションでした。その中で最も顕著なのは、Napster、KaZaA、BitTorrent [2]などが1億人以上のユーザーを支援することができる大規模なファイル配信システムを提供したことです。今日でさえ、BitTorrentは、毎日数千万のノードが入れ替わりに大規模なネットワークを維持しています。これらのアプリケーションでは、学術的に作られたファイルシステムよりも多くのユーザーとファイルが配布されていました。しかし、アプリケーションは、基盤となるインフラストラクチャとして設計されていませんでした。¹そのため、これまでグローバルな低レイテンシのもっと一般的な分散ファイルシステムは登場していませんでした。

この理由はおそらく、大部分のユースケースには十分に良いHTTPというシステムがすでに存在しているからです。HTTPはこれまでに利用可能なシステムのなかで最も成功した“分散シファイルシステム”です。ブラウザと組み合わせることでHTTPは、技術的および社会的に大きなインパクトを生みました。HTTPはインターネットを介してファイルを送信するデファクトスタンダードになっています。しかし、過去15年間に発明された何十もの素晴らしいファイル配布技術を取り入れることに失敗しています。この理由として有力な観点は、後方

互換性の制約の数と現状のモデルに投資している強力なプレイヤーの数を考慮すると、Webインフラストラクチャの進化は、ほぼ不可能です。しかし、別の観点では、HTTPの出現以降も、新しいプロトコルが登場して広く利用されています。なので欠けているのは、現在のHTTP Webを強化し、ユーザーエクスペリエンスを損なうことなく新しい機能を導入するという設計のアップグレードなのです。

小さなサイズのファイルを移動の場合、トラフィックの多い小規模な組織であっても、比較的安価であるため、業界ではこれまでHTTPが使われてきました。しかし、我々は、データの送受信に関して新たな時代へ突入しようとしています。その例をいくつか挙げます。(a) ペタバイトのデータセットホスト/配布 (b) 組織全体で大規模データを利用/計算 (c) 大容量の高画質オンデマンドまたはリアルタイムメディア配信 (d) 大規模なデータセットのバージョン管理とリンク (e) 重要なファイルの偶発的な削除の防止などが挙げられます。重要な機能のためや帯域幅の問題のために、私たちは既に異なるデータ配信プロトコルを使い、HTTPをあきらめています。Webの次のステップは、それらHTTP以外のデータ通信プロトコルをWeb自体の一部にすることです。

HTTPプロトコルは小容量のデータのやりとりに関して比較的安価で行うことを実現する一方で我々はデータ転送に関して新たな時代に突入しつつあります。それは(a) ペタバイト級データのホストと配信 (b) 組織横断の大量データ処理 (c) 大容量高画質のオンデマンドのコンテンツストリーミング (d) 大規模データのバージョン管理およびリンク処理 (e) 重要データの消失防止、というようなものが要求される時代です。このような状況のもと、我々はHTTPを捨てて新たなデータ転送プロトコルを開発しました。次のステップはこれをWebそのものにする必要があります。

効率的なデータ配信とは別軸で、バージョン管理システムは重要なデータの協業ワークフロー開発を可能にしました。分散ソースコードバージョン管理システムであるGitは、分散データの処理をモデル化して実装するたときの多くの有用な方法を作り出しました。Gitツールチェーンは、大規模なファイル配布システムには欠けている多彩なバージョン管理機能を提供してくれます。Camlistore~[?]、パーソナルファイルストレージシステム、データコラボレーションツールチェーンとデータセットパッケージマネージャーのDat~[?]など、Gitに触発された新しいソリューションが登場しています。Gitは、コンテンツアドレスMerkle DAGデータモデルを用いることによって強力なファイル分散戦略を可能にし、分散ファイルシステムの設計~[9]に既に影響を与えています。どのデータ構造がハイスループット指向のファイルシステムの設計に良いのか、どのようにWeb自体をアップグレードするかについては、まだ探求中です。

この論文では、これらの問題を解決するための新しいピアツーピアのバージョン管理ファイルシステムであるIPFSを紹介

¹例えば、BitTorrentを使ってディスクイメージを転送したり、Blizzard, Inc. はそれを使ってビデオゲームコンテンツを配信しています。

紹介します。IPFS は過去の多くの成功したシステムから学び、新しいものを作っています。インターフェイスを重視した統合を慎重に行うことで、細かいパーツの合計よりも大きなシステムとなります。中心的な IPFS の原則は、同じ Merkle DAG の一部としてすべてのデータをモデリングすることです。

2. BACKGROUND

このセクションでは IPFS に組み込まれているピアツーピアシステムで成功を納めている重要な要素についてレビューしていきます。

2.1 Distributed Hash Tables

分散ハッシュテーブル (DHTs) はピアツーピアシステムに開するメタデータを広く分配して保持する仕組みとして使われます。

2.1.1 Kademlia DHT

Kademlia [10] は人気の高い DHT です:

- 膨大なネットワーク上で効率的な検索が可能: システムの全ノード数を n とするとき、問い合わせ対象は、平均 $\lceil \log_2(n) \rceil$ のオーダーのホップ数でたどり着ける。(e.g. ネットワーク全体に 10,000,000 ノード存在するとき、 $\log_2(10,000,000) \approx 20$ このホップでたどり着ける。)
- オーバーヘッドが低い: ノード間で送受信されるいくつものコントロールメッセージが最適化されている。
- 長く使われているノードを優先する設計で様々な攻撃に対する耐性がある。
- Gnutella や BitTorrent などのピアツーピアアプリケーションで使われた実績があり、2000 万ノード以上のがネットワーク形成に成功している。 [16].

2.1.2 Coral DSHT

いくつかのピアツーピアファイルシステムではデータブロックを直接 DHT に保管します。この場合、必要のないノードにもデータを保管するしなくてはならず、ストレージと帯域幅が無駄にします。~[5] Coral DSHT は Kademlia DHT に対して 3 つに重要な拡張を行いました。

- Kademlia では、XOR 距離を用いてデータのキーの値にもっとも近いノード id をもつノードに値を格納します。ここでは、データを格納するノードがその情報を必要か否かによらず、XOR 距離がもっとも近いノードに保管させ、アプリケーションがどこに配置されているかや、アプリの都合ですでにデータを持っているノードなどを考慮せず行われています。そのため、重要なストレージと帯域幅が無駄になっていました。Coral では代わりに誰がブロックデータを持っているかのアドレスを提供することにしました。
- Coral は、DHT の API において `get_value(key)` を `get_any_values(key)` に緩和しています (Distributed Sloppy Hash Table の Sloppy の由来)。これにより key へのアクセスが増加した際に特定のノードに負荷が集中しホットスポットになることを防いでいます。
- さらに Coral では、サイズや範囲によって *clusters* と呼ばれる DHST の階層構造を構築します。はじめに *clusters* 内で対象のデータの問い合わせを行い、遠いノードへの問い合わせを行わなくても良い設計になっています [5]。そうすることで検索にかかる時間を大幅に短縮することができます。

2.1.3 S/Kademlia DHT

S/Kademlia [1] は、Kademlia を悪意のある攻撃を防ぐために以下の重要な二つの点で拡張しています。

- S/Kademlia ではセキュアな `NodeId` 生成を行いシビル攻撃の耐性を向上しています。具体的には、ノードに対して PKI key のペアの生成要求し、それを用いてアイデンティティを確保し、お互いにメッセージに署名を行うようにしています。シビルアタックのコストを上げるための一つの方法は Proof of work を使うことです。
- S/Kademlia では、ネットワークの大部分が悪意のあるノードである状況でも、データ検索時にホストノード同士が接続できるよう、分離されたパス上の値も参照できます。S / Kademlia では、ノードの半分程度が悪意のあるノードの場合でも 85% の割合でデータの参照ができます。

2.2 Block Exchanges - BitTorrent

BitTorrent [3] は、ピア (swarm) のネットワークにおいて、トレストレスにファイルピース (ファイルの断片) を互いに配布することに成功し、広く使われているピアツーピアファイル共有システムです。IPFS 設計を行う際に、BitTorrent とそのエコシステムから取り入れた機能は次の通りです。

- BitTorrent のデータ交換プロトコルは、データの送受信でネットワークに貢献するノードに報酬を与え、他人のリソースを奪うだけのノードを処罰するため疑似 tit-for-tat (しつぺ返し) 戦略という仕組みを採用しています。
- BitTorrent ピアはファイルの可用性を追跡し、最初に希少なファイルピースを優先して送信します。これは、(ファイルを丸ごと持っているピアである) シードの負荷を下げ、非シードのピア同士が互いにファイルピースを取り引できるようにします。
- 上で挙げて、BitTorrent でのデフォルトで設定されている tit-for-tat 戦略は、帯域幅の搾取 (exploitative bandwidth sharing strategies) に対して脆弱性があります。PropShare [8] は、この脆弱性を改善し、swarm のパフォーマンスを向上させ、ピアごとに帯域幅割り当てる戦略です。

2.3 Version Control Systems - Git

バージョン管理システムは、時間の経過とともに編集され変化するファイルをモデル化し、異なるバージョンを効率的に配布することを可能にします。一般的なバージョン管理システムである Git は、変更点をファイルシステムツリーとして蓄積するオブジェクトモデルで、分散システムフレンドリーな Merkle DAG が採用されています。²

- ファイル (blob), ディレクトリー (tree), 変更 (commit) は、作成後は状態が変わらないオブジェクトとして表現されます。
- それらのオブジェクトは、コンテンツを暗号的にハッシュ化したアドレスによって参照されます。
- Merkle DAG を用いて他のオブジェクトへのリンクが埋め込まれます。Merkle DAG を利用することで、データの完全性とワークフローのプロパティをユーザーに提供します。

²Merkle Directed Acyclic Graph は、Merkle Tree と似ていますが、より一般的な構造をとります。具体的には、重複除外、リーフの数の調整が必要ない、リーフノードにはデータが含まれないという特徴があります。Merkle DAG Merkle Tree の違いがぼんやりとしかわかっていない。

- ほとんどのバージョン管理用の (ブランチやタグなどの) メタデータは、参照先を指すポインターであるため、作成と更新は安価です。
- バージョンの変更では、オブジェクトの追加と参照先の更新のみが行われます。
- Distributing version changes to other users is simply transferring objects and updating remote references. バージョン変更を他のユーザーに配布する場合、単に更新履歴を含むオブジェクトを送信しリモートでそれを参照し、自分のデータを更新することができます。(この訳でいいか不安)

2.4 Self-Certified Filesystems - SFS

SFS [12, 11] は、分散トラストチェーンと平等な共有名前空間を実現するために必要な実装です。Self-Certified Filesystemsを導入するために以下に示す方法でリモートファイルシステムにおけるファイルのアドレスを定義します。

```
/sfs/<Location>:<HostID>
```

ここで Location は、サーバーのネットワークアドレスで、Host ID は、

```
HostID = hash(public_key || Location)
```

で定義します。

したがって、SFS ファイルシステムで textit name は、そのサーバーの正当性を保証します。ユーザーは、サーバーが提供する公開鍵を確認し、共有鍵を共有することで、その後のすべての通信を秘匿化することができます。すべての SFS インスタンスは、中央機関が管理せず、暗号的に決定されたグローバルな名前空間によって共有されます。

3. IPFS DESIGN

IPFS は、DHT、BitTorrent、Git、および SFS を含む以前のピアツーピアシステムから成功したアイデアを組み合わせた分散ファイルシステムです。IPFS のコントリビューションは、実証済みの技術を単純化し、進化させ、一つのシステムとしてまとめ上げたことです。IPFS は、アプリケーションの作成とデプロイのための新しいプラットフォームと、大規模データの配布とバージョン管理のための新しいシステムを提供します。したがって、IPFS はウェブ自体を進化させる可能性もあるわけです。

IPFS はピアツーピアシステムで特定のノードに特権などはありません。IPFS のノードは、ローカルストレージに IPFS のオブジェクトを保存します。ノードは互いに接続してオブジェクトを転送します。これらのオブジェクトは、ファイルおよびその他のデータ構造です。以下では、実際に IPFS について詳しく見ていくために、様々な関数を実行するための個々のプロトコルについて見ていきます。

- Identities** - ノードの Id の発行と検証を行います。Section 3.1 で説明します。
- Network** - 下位の様々な通信プロトコルを利用してピア同士の接続を管理します。変更可能です。Section 3.2 で説明します。
- Routing** - オブジェクトや特定のピアの場所に関する情報を保持します。また、ローカルとリモートクエリー両方に応答します。デフォルトでは、DHT が使われていますが変更可能です。Section 3.3 で説明します。

- Exchange** - 革新的な Block の交換プロトコルである BitSwap によって効率的な Block の交換が行われます。データのコピーを保管することが緩やかなインセンティブとなるようなマーケットを設計します。ブロック交換の戦略は変更可能です。Section 3.4 で説明します。
- Objects** - 作成後変更できないイミュータブル性と、リンクを持ったコンテンツアドレス型の Merkle DAG です。任意のデータストラクチャーを表現するために使われます。オブジェクトの例としてファイルの階層構造や通信システムなどがこれに当たります。Section 3.5 で説明します。
- Files** - Git にインスパイヤーされたファイルのバージョン管理と階層構造を持ったシステムです。Section 3.6 で説明します。
- Naming** - 自己証明 (検証) と変更が可能な名前システム。Section 3.7 で説明します。

これらのサブシステムはそれぞれが独立したものではありません。これらは組み合わせて活用されているプロパティです。しかし、今列挙したように、それらを別々に記述するとわかりやすいです。

Notation : 以下のデータ構造と関数は Go 言語の構文で書かれています。

3.1 Identities

ノードは、S/Kademlia の静的な暗号化~[1] によって作成された公開鍵をハッシュ化³ した NodeId によって識別されます。ノードは、パブリックキーと (パズルで暗号化されている) プライベートキーを保存します。ユーザーは、ノードの起動時に「新しい」ノード id を自由に作成可能です。しかし、新しく id を発行すると貰えるはずだったネットワークでの報酬がもらえなくなってしまう。そこで、ユーザーには、ノードの id をそのままにしておく方がいいというインセンティブが働きます。

```
type NodeId Multihash
type Multihash []byte
// self-describing cryptographic hash digest

type PublicKey []byte
type PrivateKey []byte
// self-describing keys

type Node struct {
    NodeId NodeId
    PubKey PublicKey
    PriKey PrivateKey
}
```

S/Kademlia に基づいた IPFS における id 生成:

```
difficulty = <integer parameter>
n = Node{}
do {
    n.PubKey, n.PrivKey = PKI.genKeyPair()
    n.NodeId = hash(n.PubKey)
    p = count_preceding_zero_bits(hash(n.NodeId))
} while (p < difficulty)
```

³このドキュメントでは、ハッシュ (hash) とチェックサム (checksum) は、特にデータの暗号的なハッシュ値という意味で用います。

今まで接続をしていないピアとの初回の接続の際、ピア同士は公開鍵を交換し、`hash(other.PublicKey)=other.NodeId`をチェックします。この値が一致しなければ、接続は終了し、値が一致すれば接続を開始します。

Note on Cryptographic Functions.

IPFS では、システムで使われる関数を特定の関数やその組み合わせに固定せず、それがそのような関数で実行されたのかを記述するような仕様になっています。そのため、ハッシュダイジェスト値は、マルチハッシュ形式で保存されます。この形式には、使用されるハッシュ関数を指定する短いヘッダーと、バイト単位でのダイジェスト長が含まれます。例えば、

```
<function code><digest length><digest bytes>
```

のように記述されます。

このように冗長性を持たせることによって、(a)(強いセキュリティが必要な場合やスピードが求められる場合など) ユースケースを考慮して関数を選ぶことができます。(b) 暗号学の発展やより良い関数が発明されたときに新しく良いものを利用でき、それらに互換性をもたせることができます。

3.2 Network

IPFS のノードは、幅広い範囲のネットワーク上の何百もの他のノードと通信をしています。ここでは、IPFS のネットワークスタックの特徴について説明します。

- **Transport:** IPFS は、どのトランスポート層のプロトコルも利用できます。特に、WebRTC DataChannels [?] (for browser connectivity) や uTP(LEDBAT [14]). との相性がいいです。
- **Reliability:** IPFS は、uTP (LEDBAT [14]) や SCTP [15] を利用することで、下位のネットワークに信頼性がなくても信頼性を確保できます。
- **Connectivity:** IPFS は、ICE-NAT-traversal[13] を利用しています。
- **Integrity:** オプションとして、メッセージのチェックサムを利用してメッセージの完全性を確認できます。
- **Authenticity:** オプションとして、メッセージの送り手の秘密鍵を用いてデジタル署名をメッセージに添付することができ、これを検証することができます。

3.2.1 Note on Peer Addressing

IPFS では、任意のネットワークを使用することができます。これは、インターネットプロトコル (IP) のみを頼り、それのみにアクセスするということではありません⁴。そのため、オーバーレイネットワークでも IPFS を使用することができます。IPFS は、使用するネットワークに関するアドレスを `multiaddr` フォーマットでバイト列として保存します。`multiaddr` は、使用しているネットワークのプロトコルとそこでのアドレスを記録し、それらをカプセル化する技術を提供します。例えば、

```
# an SCTP/IPv4 connection
/ip4/10.20.30.40/sctp/1234/
```

```
# an SCTP/IPv4 connection proxied over TCP/IPv4
/ip4/5.6.7.8/tcp/5678/ip4/1.2.3.4/sctp/1234/
```

のように記述されます。

⁴したがって、IP やそのバージョンにも依存しません (翻訳者注)

3.3 Routing

IPFS nodes require a routing system that can find (a) other peers' network addresses and (b) peers who can serve particular objects. IPFS achieves this using a DSHT based on S/Kademlia and Coral, using the properties discussed in 2.1. The size of objects and use patterns of IPFS are similar to Coral [5] and Mainline [16], so the IPFS DHT makes a distinction for values stored based on their size. Small values (equal to or less than 1KB) are stored directly on the DHT. For larger values, the DHT stores references, which are the `NodeIds` of peers who can serve the block.

The interface of this DSHT is the following:

```
type IPFSRouting interface {

    FindPeer(node NodeId)
    // gets a particular peer's network address

    SetValue(key []bytes, value []bytes)
    // stores a small metadata value in DHT

    GetValue(key []bytes)
    // retrieves small metadata value from DHT

    ProvideValue(key Multihash)
    // announces this node can serve a large value

    FindValuePeers(key Multihash, min int)
    // gets a number of peers serving a large value
}
```

Note: different use cases will call for substantially different routing systems (e.g. DHT in wide network, static HT in local network). Thus the IPFS routing system can be swapped for one that fits users' needs. As long as the interface above is met, the rest of the system will continue to function.

3.4 Block Exchange - BitSwap Protocol

In IPFS, data distribution happens by exchanging blocks with peers using a BitTorrent inspired protocol: BitSwap. Like BitTorrent, BitSwap peers are looking to acquire a set of blocks (`want_list`), and have another set of blocks to offer in exchange (`have_list`). Unlike BitTorrent, BitSwap is not limited to the blocks in one torrent. BitSwap operates as a persistent marketplace where node can acquire the blocks they need, regardless of what files those blocks are part of. The blocks could come from completely unrelated files in the filesystem. Nodes come together to barter in the marketplace.

While the notion of a barter system implies a virtual currency could be created, this would require a global ledger to track ownership and transfer of the currency. This can be implemented as a BitSwap Strategy, and will be explored in a future paper.

In the base case, BitSwap nodes have to provide direct value to each other in the form of blocks. This works fine when the distribution of blocks across nodes is complementary, meaning they have what the other wants. Often, this will not be the case. In some cases, nodes must *work* for their blocks. In the case that a node has nothing that its peers want (or nothing at all), it seeks the pieces its peers want, with lower priority than what the node wants itself.

This incentivizes nodes to cache and disseminate rare pieces, even if they are not interested in them directly.

3.4.1 BitSwap Credit

The protocol must also incentivize nodes to seed when they do not need anything in particular, as they might have the blocks others want. Thus, BitSwap nodes send blocks to their peers optimistically, expecting the debt to be repaid. But leeches (free-loading nodes that never share) must be protected against. A simple credit-like system solves the problem:

1. Peers track their balance (in bytes verified) with other nodes.
2. Peers send blocks to debtor peers probabilistically, according to a function that falls as debt increases.

Note that if a node decides not to send to a peer, the node subsequently ignores the peer for an `ignore_cooldown` timeout. This prevents senders from trying to game the probability by just causing more dice-rolls. (Default BitSwap is 10 seconds).

3.4.2 BitSwap Strategy

The differing strategies that BitSwap peers might employ have wildly different effects on the performance of the exchange as a whole. In BitTorrent, while a standard strategy is specified (tit-for-tat), a variety of others have been implemented, ranging from BitTyrant [8] (sharing the least-possible), to BitThief [8] (exploiting a vulnerability and never share), to PropShare [8] (sharing proportionally). A range of strategies (good and malicious) could similarly be implemented by BitSwap peers. The choice of function, then, should aim to:

1. maximize the trade performance for the node, and the whole exchange
2. prevent freeloaders from exploiting and degrading the exchange
3. be effective with and resistant to other, unknown strategies
4. be lenient to trusted peers

The exploration of the space of such strategies is future work. One choice of function that works in practice is a sigmoid, scaled by a *debt ratio*:

Let the *debt ratio* r between a node and its peer be:

$$r = \frac{\text{bytes_sent}}{\text{bytes_recv} + 1}$$

Given r , let the probability of sending to a debtor be:

$$P(\text{send} | r) = 1 - \frac{1}{1 + \exp(6 - 3r)}$$

As you can see in Figure ??, this function drops off quickly as the nodes' *debt ratio* surpasses twice the established credit. The *debt ratio* is a measure of trust: lenient to debts between nodes that have previously exchanged lots of data successfully, and merciless to unknown, untrusted nodes. This (a) provides resistance to attackers who would create lots of new nodes (sybil attacks), (b) protects previously successful trade relationships, even if one of the nodes is temporarily unable to provide value, and (c) eventually chokes relationships that have deteriorated until they improve.

3.4.3 BitSwap Ledger

BitSwap nodes keep ledgers accounting the transfers with other nodes. This allows nodes to keep track of history and avoid tampering. When activating a connection, BitSwap nodes exchange their ledger information. If it does not match exactly, the ledger is reinitialized from scratch, losing the accrued credit or debt. It is possible for malicious nodes to purposefully "lose" the Ledger, hoping to erase debts. It is unlikely that nodes will have accrued enough debt to warrant also losing the accrued trust; however the partner node is free to count it as misconduct, and refuse to trade.

```
type Ledger struct {
    owner      NodeId
    partner    NodeId
    bytes_sent int
    bytes_recv int
    timestamp  Timestamp
}
```

Nodes are free to keep the ledger history, though it is not necessary for correct operation. Only the current ledger entries are useful. Nodes are also free to garbage collect ledgers as necessary, starting with the less useful ledgers: the old (peers may not exist anymore) and small.

3.4.4 BitSwap Specification

BitSwap nodes follow a simple protocol.

```
// Additional state kept
type BitSwap struct {
    ledgers map[NodeId]Ledger
    // Ledgers known to this node, inc inactive

    active map[NodeId]Peer
    // currently open connections to other nodes

    need_list []Multihash
    // checksums of blocks this node needs

    have_list []Multihash
    // checksums of blocks this node has
}

type Peer struct {
    nodeid NodeId
    ledger Ledger
    // Ledger between the node and this peer

    last_seen Timestamp
    // timestamp of last received message

    want_list []Multihash
    // checksums of all blocks wanted by peer
    // includes blocks wanted by peer's peers
}

// Protocol interface:
interface Peer {
    open (nodeid :NodeId, ledger :Ledger);
    send_want_list (want_list :WantList);
    send_block (block :Block) -> (complete :Bool);
    close (final :Bool);
}
```

Sketch of the lifetime of a peer connection:

1. Open: peers send `ledgers` until they agree.
2. Sending: peers exchange `want_lists` and `blocks`.
3. Close: peers deactivate a connection.
4. Ignored: (special) a peer is ignored (for the duration of a timeout) if a node's strategy avoids sending

Peer.open(NodeId, Ledger).

When connecting, a node initializes a connection with a `Ledger`, either stored from a connection in the past or a new one zeroed out. Then, sends an Open message with the `Ledger` to the peer.

Upon receiving an `Open` message, a peer chooses whether to activate the connection. If – according to the receiver's `Ledger` – the sender is not a trusted agent (transmission below zero, or large outstanding debt) the receiver may opt to ignore the request. This should be done probabilistically with an `ignore_cooldown` timeout, as to allow errors to be corrected and attackers to be thwarted.

If activating the connection, the receiver initializes a `Peer` object with the local version of the `Ledger` and sets the `last_seen` timestamp. Then, it compares the received `Ledger` with its own. If they match exactly, the connections have opened. If they do not match, the peer creates a new zeroed out `Ledger` and sends it.

Peer.send_want_list(WantList).

While the connection is open, nodes advertise their `want_list` to all connected peers. This is done (a) upon opening the connection, (b) after a randomized periodic timeout, (c) after a change in the `want_list` and (d) after receiving a new block.

Upon receiving a `want_list`, a node stores it. Then, it checks whether it has any of the wanted blocks. If so, it sends them according to the *BitSwap Strategy* above.

Peer.send_block(Block).

Sending a block is straightforward. The node simply transmits the block of data. Upon receiving all the data, the receiver computes the Multihash checksum to verify it matches the expected one, and returns confirmation.

Upon finalizing the correct transmission of a block, the receiver moves the block from `need_list` to `have_list`, and both the receiver and sender update their ledgers to reflect the additional bytes transmitted.

If a transmission verification fails, the sender is either malfunctioning or attacking the receiver. The receiver is free to refuse further trades. Note that BitSwap expects to operate on a reliable transmission channel, so transmission errors – which could lead to incorrect penalization of an honest sender – are expected to be caught before the data is given to BitSwap.

Peer.close(Bool).

The `final` parameter to `close` signals whether the intention to tear down the connection is the sender's or not. If false, the receiver may opt to re-open the connection immediately. This avoids premature closes.

A peer connection should be closed under two conditions:

- a `silence_wait` timeout has expired without receiving any messages from the peer (default BitSwap uses 30 seconds). The node issues `Peer.close(false)`.
- the node is exiting and BitSwap is being shut down. In this case, the node issues `Peer.close(true)`.

After a `close` message, both receiver and sender tear down the connection, clearing any state stored. The `Ledger` may be stored for the future, if it is useful to do so.

Notes.

- Non-open messages on an inactive connection should be ignored. In case of a `send_block` message, the receiver may check the block to see if it is needed and correct, and if so, use it. Regardless, all such out-of-order messages trigger a `close(false)` message from the receiver to force re-initialization of the connection.

3.5 Object Merkle DAG

The DHT and BitSwap allow IPFS to form a massive peer-to-peer system for storing and distributing blocks quickly and robustly. On top of these, IPFS builds a Merkle DAG, a directed acyclic graph where links between objects are cryptographic hashes of the targets embedded in the sources. This is a generalization of the Git data structure. Merkle DAGs provide IPFS many useful properties, including:

1. **Content Addressing:** all content is uniquely identified by its multihash checksum, **including links**.
2. **Tamper resistance:** all content is verified with its checksum. If data is tampered with or corrupted, IPFS detects it.
3. **Deduplication:** all objects that hold the exact same content are equal, and only stored once. This is particularly useful with index objects, such as git **trees** and **commits**, or common portions of data.

The IPFS Object format is:

```
type IPFSLink struct {
    Name string
    // name or alias of this link

    Hash Multihash
    // cryptographic hash of target

    Size int
    // total size of target
}

type IPFSObject struct {
    links []IPFSLink
    // array of links

    data []byte
    // opaque content data
}
```


The IPFS Merkle DAG is an extremely flexible way to store data. The only requirements are that object references be (a) content addressed, and (b) encoded in the format above. IPFS grants applications complete control over the data field; applications can use any custom data format they choose, which IPFS may not understand. The separate in-object link table allows IPFS to:

- List all object references in an object. For example:

```
> ipfs ls /XLZ1625Jjn7SubMDgEyeaynFuR84ginqvzb
XLYkgq61DYaQ8NhkcqyU7rLcnSa7dSHQ16x 189458 less
XLHBNmRQ5sJJrdMPuu48pzeyTtRo39tNDR5 19441 script
XLF4hwVhsVuZ78FZK6fozf8Jj9WEURMbCX4 5286 template
```

```
<object multihash> <object size> <link name>
```

- Resolve string path lookups, such as `foo/bar/baz`. Given an object, IPFS resolves the first path component to a hash in the object's link table, fetches that second object, and repeats with the next component. Thus, string paths can walk the Merkle DAG no matter what the data formats are.
- Resolve all objects referenced recursively:

```
> ipfs refs --recursive \
  /XLZ1625Jjn7SubMDgEyeaynFuR84ginqvzb
XLLxhdgJcXzLbtsLRL1twCHA2NrURp4H38s
XLYkgq61DYaQ8NhkcqyU7rLcnSa7dSHQ16x
XLHBNmRQ5sJJrdMPuu48pzeyTtRo39tNDR5
XLWVQDqxo9Km9zLYquoC9gAP8CL1gWnHZ7z
...
```

A raw data field and a common link structure are the necessary components for constructing arbitrary data structures on top of IPFS. While it is easy to see how the Git object model fits on top of this DAG, consider these other potential data structures: (a) key-value stores (b) traditional relational databases (c) Linked Data triple stores (d) linked document publishing systems (e) linked communications platforms (f) cryptocurrency blockchains. These can all be modeled on top of the IPFS Merkle DAG, which allows any of these systems to use IPFS as a transport protocol for more complex applications.

3.5.1 Paths

IPFS objects can be traversed with a string path API. Paths work as they do in traditional UNIX filesystems and the Web. The Merkle DAG links make traversing it easy. Note that full paths in IPFS are of the form:

```
# format
/ipfs/<hash-of-object>/<name-path-to-object>

# example
/ipfs/XLYkgq61DYaQ8NhkcqyU7rLcnSa7dSHQ16x/foo.txt
```

The `/ipfs` prefix allows mounting into existing systems at a standard mount point without conflict (mount point names are of course configurable). The second path component (first within IPFS) is the hash of an object. This is always the case, as there is no global root. A root object would have the impossible task of handling consistency

of millions of objects in a distributed (and possibly disconnected) environment. Instead, we simulate the root with content addressing. All objects are always accessible via their hash. Note this means that given three objects in path `<foo>/bar/baz`, the last object is accessible by all:

```
/ipfs/<hash-of-foo>/bar/baz
/ipfs/<hash-of-bar>/baz
/ipfs/<hash-of-baz>
```

3.5.2 Local Objects

IPFS clients require some *local storage*, an external system on which to store and retrieve local raw data for the objects IPFS manages. The type of storage depends on the node's use case. In most cases, this is simply a portion of disk space (either managed by the native filesystem, by a key-value store such as leveldb [4], or directly by the IPFS client). In others, for example non-persistent caches, this storage is just a portion of RAM.

Ultimately, all blocks available in IPFS are in some node's *local storage*. When users request objects, they are found, downloaded, and stored locally, at least temporarily. This provides fast lookup for some configurable amount of time thereafter.

3.5.3 Object Pinning

Nodes who wish to ensure the survival of particular objects can do so by **pinning** the objects. This ensures the objects are kept in the node's *local storage*. Pinning can be done recursively, to pin down all linked descendent objects as well. All objects pointed to are then stored locally. This is particularly useful to persist files, including references. This also makes IPFS a Web where links are *permanent*, and Objects can ensure the survival of others they point to.

3.5.4 Publishing Objects

IPFS is globally distributed. It is designed to allow the files of millions of users to coexist together. The DHT, with content-hash addressing, allows publishing objects in a fair, secure, and entirely distributed way. Anyone can publish an object by simply adding its key to the DHT, adding themselves as a peer, and giving other users the object's path. Note that Objects are essentially immutable, just like in Git. New versions hash differently, and thus are new objects. Tracking versions is the job of additional versioning objects.

3.5.5 Object-level Cryptography

IPFS is equipped to handle object-level cryptographic operations. An encrypted or signed object is wrapped in a special frame that allows encryption or verification of the raw bytes.

```
type EncryptedObject struct {
    Object []bytes
    // raw object data encrypted

    Tag []bytes
    // optional tag for encryption groups
}

type SignedObject struct {
    Object []bytes
    // raw object data signed
```

```

Signature []bytes
// hmac signature

PublicKey []multihash
// multihash identifying key
}

```

Cryptographic operations change the object's hash, defining a different object. IPFS automatically verifies signatures, and can decrypt data with user-specified keychains. Links of encrypted objects are protected as well, making traversal impossible without a decryption key. It is possible to have a parent object encrypted under one key, and a child under another or not at all. This secures links to shared objects.

3.6 Files

IPFS also defines a set of objects for modeling a versioned filesystem on top of the Merkle DAG. This object model is similar to Git's:

1. **block**: a variable-size block of data.
2. **list**: a collection of blocks or other lists.
3. **tree**: a collection of blocks, lists, or other trees.
4. **commit**: a snapshot in the version history of a tree.

We hoped to use the Git object formats exactly, but had to depart to introduce certain features useful in a distributed filesystem, namely (a) fast size lookups (aggregate byte sizes have been added to objects), (b) large file deduplication (adding a **list** object), and (c) embedding of **commits** into **trees**. However, IPFS File objects are close enough to Git that conversion between the two is possible. Also, a set of Git objects can be introduced to convert without losing any information (unix file permissions, etc).

Notation: File object formats below use JSON. Note that this structure is actually binary encoded using protobufs, though ipfs includes import/export to JSON.

3.6.1 File Object: blob

The **blob** object contains an addressable unit of data, and represents a file. IPFS Blocks are like Git blobs or filesystem data blocks. They store the users' data. Note that IPFS files can be represented by both **lists** and **blobs**. Blobs have no links.

```

{
  "data": "some data here"
  // blobs have no links
}

```

3.6.2 File Object: list

The **list** object represents a large or deduplicated file made up of several IPFS **blobs** concatenated together. **lists** contain an ordered sequence of **blob** or **list** objects. In a sense, the IPFS **list** functions like a filesystem file with indirect blocks. Since **lists** can contain other **lists**, topologies including linked lists and balanced trees are possible. Directed graphs where the same node appears in multiple places allow in-file deduplication. Of course, cycles are not possible, as enforced by hash addressing.

```

> ipfs file-cat <ccc111-hash> --json
{
  "data": {
    "type": "tree",
    "date": "2014-09-20 12:44:06Z",
    "message": "This is a commit message."
  },
  "links": [
    { "hash": "<ccc000-hash>",
      "name": "parent", "size": 25309 },
    { "hash": "<ttt111-hash>",
      "name": "object", "size": 5198 },
    { "hash": "<aaa111-hash>",
      "name": "author", "size": 109 }
  ]
}

> ipfs file-cat <ttt111-hash> --json
{
  "data": nil,
  "links": [
    { "hash": "<ttt222-hash>",
      "name": "ttt222-name", "size": 1234 },
    { "hash": "<ttt333-hash>",
      "name": "ttt333-name", "size": 3456 },
    { "hash": "<bbb222-hash>",
      "name": "bbb222-name", "size": 22 }
  ]
}

> ipfs file-cat <bbb222-hash> --json
{
  "data": "blob222 data",
  "links": []
}

```

Figure 1: Sample Objects

```

{
  "data": ["blob", "list", "blob"],
  // lists have an array of object types as data
  "links": [
    { "hash": "XLYkgq61DYaQ8NhkcqyU7rLcnSa7dSHQ16x",
      "size": 189458 },
    { "hash": "XLHBNmRQ5sJJrdMPuu48pzeyTtRo39tNDR5",
      "size": 19441 },
    { "hash": "XLWVQDqxo9Km9zLyquoC9gAP8CL1gWnHZ7z",
      "size": 5286 }
  ]
  // lists have no names in links
}

```

3.6.3 File Object: tree

The **tree** object in IPFS is similar to Git's: it represents a directory, a map of names to hashes. The hashes reference **blobs**, **lists**, other **trees**, or **commits**. Note that traditional path naming is already implemented by the Merkle DAG.

```

{
  "data": nil,
  // trees have no data, only links
}

```



```

"links": [
  { "hash": "XLYkgq61DYaq8NhkcqyU7rLcnSa7dSHQ16x",
    "name": "less", "size": 189458 },
  { "hash": "XLHBNmRQ5sJJrdMPuu48pzeyTtRo39tNDR5",
    "name": "script", "size": 19441 },
  { "hash": "XLWVQDqxo9Km9zLyquoc9gAP8CL1gWnHZ7z",
    "name": "template", "size": 5286 }
]
// trees do have names
}

```

3.6.4 File Object: commit

The `commit` object in IPFS represents a snapshot in the version history of any object. It is similar to Git's, but can reference any type of object. It also links to author objects.

```

{
  "data": {
    "type": "tree",
    "date": "2014-09-20 12:44:06Z",
    "message": "This is a commit message."
  },
  "links": [
    { "hash": "XLa1qMBKiSEEDhojb9FFZ4tEvLf7FEQdhdU",
      "name": "parent", "size": 25309 },
    { "hash": "XLGw74KAy9junbh28x7ccWov9inu1Vo7pnX",
      "name": "object", "size": 5198 },
    { "hash": "XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm",
      "name": "author", "size": 109 }
  ]
}

```

3.6.5 Version control

The `commit` object represents a particular snapshot in the version history of an object. Comparing the objects (and children) of two different commits reveals the differences between two versions of the filesystem. As long as a single `commit` and all the children objects it references are accessible, all preceding versions are retrievable and the full history of the filesystem changes can be accessed. This falls out of the Merkle DAG object model.

The full power of the Git version control tools is available to IPFS users. The object model is compatible, though not the same. It is possible to (a) build a version of the Git tools modified to use the IPFS object graph, (b) build a mounted FUSE filesystem that mounts an IPFS `tree` as a Git repo, translating Git filesystem read/writes to the IPFS formats.

3.6.6 Filesystem Paths

As we saw in the Merkle DAG section, IPFS objects can be traversed with a string path API. The IPFS File Objects are designed to make mounting IPFS onto a UNIX filesystem simpler. They restrict `trees` to have no data, in order to represent them as directories. And `commits` can either be represented as directories or hidden from the filesystem entirely.

3.6.7 Splitting Files into Lists and Blob

One of the main challenges with versioning and distributing large files is finding the right way to split them into independent blocks. Rather than assume it can make the right decision for every type of file, IPFS offers the following alternatives:

- Use Rabin Fingerprints [?] as in LBFS [?] to pick suitable block boundaries.
- Use the rsync [?] rolling-checksum algorithm, to detect blocks that have changed between versions.
- Allow users to specify block-splitting functions highly tuned for specific files.

3.6.8 Path Lookup Performance

Path-based access traverses the object graph. Retrieving each object requires looking up its key in the DHT, connecting to peers, and retrieving its blocks. This is considerable overhead, particularly when looking up paths with many components. This is mitigated by:

- tree caching:** since all objects are hash-addressed, they can be cached indefinitely. Additionally, `trees` tend to be small in size so IPFS prioritizes caching them over `blobs`.
- flattened trees:** for any given `tree`, a special `flattened tree` can be constructed to list all objects reachable from the `tree`. Names in the `flattened tree` would really be paths parting from the original tree, with slashes.

For example, flattened `tree` for `ttt111` above:

```

{
  "data": [
    "tree", "blob", "tree", "list", "blob" "blob"],
  "links": [
    { "hash": "<ttt222-hash>", "size": 1234
      "name": "ttt222-name" },
    { "hash": "<bbb111-hash>", "size": 123,
      "name": "ttt222-name/bbb111-name" },
    { "hash": "<ttt333-hash>", "size": 3456,
      "name": "ttt333-name" },
    { "hash": "<l11111-hash>", "size": 587,
      "name": "ttt333-name/l11111-name" },
    { "hash": "<bbb222-hash>", "size": 22,
      "name": "ttt333-name/l11111-name/bbb222-name" },
    { "hash": "<bbb222-hash>", "size": 22
      "name": "bbb222-name" }
  ]
}

```

3.7 IPNS: Naming and Mutable State

So far, the IPFS stack forms a peer-to-peer block exchange constructing a content-addressed DAG of objects. It serves to publish and retrieve immutable objects. It can even track the version history of these objects. However, there is a critical component missing: mutable naming. Without it, all communication of new content must happen off-band, sending IPFS links. What is required is some way to retrieve mutable state at *the same path*.

It is worth stating why – if mutable data is necessary in the end – we worked hard to build up an *immutable* Merkle DAG. Consider the properties of IPFS that fall out of the Merkle DAG: objects can be (a) retrieved via their hash, (b) integrity checked, (c) linked to others, and (d) cached indefinitely. In a sense:

Objects are **permanent**

These are the critical properties of a high-performance distributed system, where data is expensive to move across network links. Object content addressing constructs a web with (a) significant bandwidth optimizations, (b) untrusted content serving, (c) permanent links, and (d) the ability to make full permanent backups of any object and its references.

The Merkle DAG, immutable content-addressed objects, and Naming, mutable pointers to the Merkle DAG, instantiate a dichotomy present in many successful distributed systems. These include the Git Version Control System, with its immutable objects and mutable references; and Plan9 [?], the distributed successor to UNIX, with its mutable Fossil [?] and immutable Venti [?] filesystems. LBFS [?] also uses mutable indices and immutable chunks.

3.7.1 Self-Certified Names

Using the naming scheme from SFS [12, 11] gives us a way to construct self-certified names, in a cryptographically assigned global namespace, that are mutable. The IPFS scheme is as follows.

1. Recall that in IPFS:

```
NodeId = hash(node.PubKey)
```

2. We assign every user a mutable namespace at:

```
/ipns/<NodeId>
```

3. A user can publish an Object to this path **Signed** by her private key, say at:

```
/ipns/XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm/
```

4. When other users retrieve the object, they can check the signature matches the public key and NodeId. This verifies the authenticity of the Object published by the user, achieving mutable state retrieval.

Note the following details:

- The **ipns** (InterPlanetary Name Space) separate prefix is to establish an easily recognizable distinction between *mutable* and *immutable* paths, for both programs and human readers.
- Because this is *not* a content-addressed object, publishing it relies on the only mutable state distribution system in IPFS, the Routing system. The process is (1) publish the object as a regular immutable IPFS object, (2) publish its hash on the Routing system as a metadata value:

```
routing.setValue(NodeId, <ns-object-hash>)
```

- Any links in the Object published act as sub-names in the namespace:

```
/ipns/XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm/  
/ipns/XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm/docs  
/ipns/XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm/docs/ipfs
```

- it is advised to publish a **commit** object, or some other object with a version history, so that clients may be able to find old names. This is left as a user option, as it is not always desired.

Note that when users publish this Object, it cannot be published in the same way

3.7.2 Human Friendly Names

While IPNS is indeed a way of assigning and reassigning names, it is not very user friendly, as it exposes long hash values as names, which are notoriously hard to remember. These work for URLs, but not for many kinds of offline transmission. Thus, IPFS increases the user-friendliness of IPNS with the following techniques.

Peer Links.

As encouraged by SFS, users can link other users' Objects directly into their own Objects (namespace, home, etc). This has the benefit of also creating a web of trust (and supports the old Certificate Authority model):

```
# Alice links to Bob
```

```
ipfs link /<alice-pk-hash>/friends/bob /<bob-pk-hash>
```

```
# Eve links to Alice
```

```
ipfs link /<eve-pk-hash>/friends/alice /<alice-pk-hash>
```

```
# Eve also has access to Bob
```

```
/<eve-pk-hash>/friends/alice/friends/bob
```

```
# access Verisign certified domains
```

```
/<verisign-pk-hash>/foo.com
```

DNS TXT IPNS Records.

If `/ipns/<domain>` is a valid domain name, IPFS looks up key **ipns** in its DNS TXT records. IPFS interprets the value as either an object hash or another IPNS path:

```
# this DNS TXT record
```

```
ipfs.benet.ai. TXT "ipfs=XLF2ipQ4jD3U ..."
```

```
# behaves as symlink
```

```
ln -s /ipns/XLF2ipQ4jD3U /ipns/fs.benet.ai
```

Proquint Pronounceable Identifiers.

There have always been schemes to encode binary into pronounceable words. IPNS supports Proquint [?]. Thus:

```
# this proquint phrase
```

```
/ipns/dahih-dolij-sozuk-vosah-luvar-fuluh
```

```
# will resolve to corresponding
```

```
/ipns/KhAwNprxYVxKqpDZ
```

Name Shortening Services.

Services are bound to spring up that will provide name shortening as a service, offering up their namespaces to users. This is similar to what we see today with DNS and Web URLs:

```
# User can get a link from
```

```
/ipns/shorten.er/foobar
```

```
# To her own namespace
```

```
/ipns/XLF2ipQ4jD3UdeX5xp1KBgeHRhemUtaA8Vm
```

3.8 Using IPFS

IPFS is designed to be used in a number of different ways. Here are just some of the use cases I will be pursuing:

1. As a mounted global filesystem, under `/ipfs` and `/ipns`.
2. As a mounted personal sync folder that automatically versions, publishes, and backs up any writes.
3. As an encrypted file or data sharing system.
4. As a versioned package manager for *all* software.
5. As the root filesystem of a Virtual Machine.
6. As the boot filesystem of a VM (under a hypervisor).
7. As a database: applications can write directly to the Merkle DAG data model and get all the versioning, caching, and distribution IPFS provides.
8. As a linked (and encrypted) communications platform.
9. As an integrity checked CDN for large files (without SSL).
10. As an encrypted CDN.
11. On webpages, as a web CDN.
12. As a new Permanent Web where links do not die.

The IPFS implementations target:

- (a) an IPFS library to import in your own applications.
- (b) commandline tools to manipulate objects directly.
- (c) mounted file systems, using FUSE [?] or as kernel modules.

4. THE FUTURE

The ideas behind IPFS are the product of decades of successful distributed systems research in academia and open source. IPFS synthesizes many of the best ideas from the most successful systems to date. Aside from BitSwap, which is a novel protocol, the main contribution of IPFS is this coupling of systems and synthesis of designs.

IPFS is an ambitious vision of new decentralized Internet infrastructure, upon which many different kinds of applications can be built. At the bare minimum, it can be used as a global, mounted, versioned filesystem and namespace, or as the next generation file sharing system. At its best, it could push the web to new horizons, where publishing valuable information does not impose hosting it on the publisher but upon those interested, where users can trust the content they receive without trusting the peers they receive it from, and where old but important files do not go missing. IPFS looks forward to bringing us toward the Permanent Web.

5. ACKNOWLEDGMENTS

IPFS is the synthesis of many great ideas and systems. It would be impossible to dare such ambitious goals without standing on the shoulders of such giants. Personal thanks to David Dalrymple, Joe Zimmerman, and Ali Yahya for long discussions on many of these ideas, in particular: exposing the general Merkle DAG (David, Joe), rolling hash blocking (David), and s/kademlia sybil protection (David, Ali). And special thanks to David Mazieres, for his ever brilliant ideas.

6. REFERENCES TODO

7. REFERENCES

- [1] I. Baumgart and S. Mies. S/kademlia: A practicable approach towards secure key-based routing. In *Parallel and Distributed Systems, 2007 International Conference on*, volume 2, pages 1–8. IEEE, 2007.
- [2] I. BitTorrent. Bittorrent and torrent software surpass 150 million user milestone, Jan. 2012.
- [3] B. Cohen. Incentives build robustness in bittorrent. In *Workshop on Economics of Peer-to-Peer systems*, volume 6, pages 68–72, 2003.
- [4] J. Dean and S. Ghemawat. leveldb—a fast and lightweight key/value database library by google, 2011.
- [5] M. J. Freedman, E. Freudenthal, and D. Mazieres. Democratizing content publication with coral. In *NSDI*, volume 4, pages 18–18, 2004.
- [6] J. H. Howard, M. L. Kazar, S. G. Menees, D. A. Nichols, M. Satyanarayanan, R. N. Sidebotham, and M. J. West. Scale and performance in a distributed file system. *ACM Transactions on Computer Systems (TOCS)*, 6(1):51–81, 1988.
- [7] J. Kubiatawicz, D. Bindel, Y. Chen, S. Czerwinski, P. Eaton, D. Geels, R. Gummadi, S. Rhea, H. Weatherspoon, W. Weimer, et al. Oceanstore: An architecture for global-scale persistent storage. *ACM Sigplan Notices*, 35(11):190–201, 2000.
- [8] D. Levin, K. LaCurts, N. Spring, and B. Bhattacharjee. Bittorrent is an auction: analyzing and improving bittorrent’s incentives. In *ACM SIGCOMM Computer Communication Review*, volume 38, pages 243–254. ACM, 2008.
- [9] A. J. Mashtizadeh, A. Bittau, Y. F. Huang, and D. Mazieres. Replication, history, and grafting in the ori file system. In *Proceedings of the Twenty-Fourth ACM Symposium on Operating Systems Principles*, pages 151–166. ACM, 2013.
- [10] P. Maymounkov and D. Mazieres. Kademlia: A peer-to-peer information system based on the xor metric. In *Peer-to-Peer Systems*, pages 53–65. Springer, 2002.
- [11] D. Mazieres and F. Kaashoek. Self-certifying file system. 2000.
- [12] D. Mazieres and M. F. Kaashoek. Escaping the evils of centralized control with self-certifying pathnames. In *Proceedings of the 8th ACM SIGOPS European workshop on Support for composing distributed applications*, pages 118–125. ACM, 1998.
- [13] J. Rosenberg and A. Keranen. Interactive connectivity establishment (ice): A protocol for network address translator (nat) traversal for offer/answer protocols. 2013.
- [14] S. Shalunov, G. Hazel, J. Iyengar, and M. Kuehlewind. Low extra delay background transport (ledbat). *draft-ietf-ledbat-congestion-04. txt*, 2010.
- [15] R. R. Stewart and Q. Xie. *Stream control transmission protocol (SCTP): a reference guide*. Addison-Wesley Longman Publishing Co., Inc., 2001.
- [16] L. Wang and J. Kangasharju. Measuring large-scale distributed systems: case of bittorrent mainline dht. In *Peer-to-Peer Computing (P2P), 2013 IEEE Thirteenth*

International Conference on, pages 1–10. IEEE, 2013.